

Sistema de recomendação de filmes

Tony Cleriston Oliveira dos Santos Junior¹, João Arthur Nascimento Mascarenhas²

Resumo. Este artigo apresenta o desenvolvimento de um sistema de recomendação de filmes utilizando o algoritmo Apriori. O trabalho aborda a construção de um modelo capaz de identificar padrões nos filmes avaliados positivamente pelos usuários e, com base nesses padrões, realizar recomendações personalizadas. São descritos o processo de mineração de dados, implementação do algoritmo, geração de regras de associação e avaliação dos resultados obtidos. Os experimentos demonstram que a abordagem proposta é capaz de gerar recomendações relevantes utilizando métricas como suporte, confiança e lift para avaliar a qualidade das associações identificadas.

1. Introdução

Com o crescimento exponencial da quantidade de conteúdo disponível em plataformas de streaming, os sistemas de recomendação tornaram-se essenciais para auxiliar os usuários a descobrirem novos conteúdos que possam ser de seu interesse. Entre as diversas abordagens existentes para sistemas de recomendação, os algoritmos baseados em regras de associação se destacam pela sua capacidade de identificar padrões de comportamento e preferências sem necessitar de informações detalhadas sobre os itens ou os usuários.

Neste contexto, este trabalho apresenta o desenvolvimento de um sistema de recomendação de filmes utilizando regras de associação extraídas por meio do algoritmo Apriori. Diferentemente das abordagens tradicionais de filtragem colaborativa ou baseada em conteúdo, que dependem de similaridade entre usuários ou características dos itens, nosso sistema busca identificar relações frequentes entre os filmes que foram avaliados positivamente pelos usuários.

2. Fundamentação Teórica

2.1. Regras de Associação

Regras de associação são expressões da forma $X \rightarrow Y$, onde X e Y são conjuntos de itens (itemsets). Estas regras indicam que quando o conjunto X ocorre em uma transação, o conjunto Y também tende a ocorrer. No contexto de recomendação de filmes, uma regra poderia ser interpretada como: "Usuários que gostaram dos filmes A e B também tendem a gostar do filme C".

2.2. Métricas para Avaliação de Regras

Para avaliar a qualidade e relevância das regras de associação, três métricas principais são utilizadas:

Suporte: Representa a frequência com que um conjunto de itens aparece no conjunto de dados. Para um conjunto de itens X.

Confiança: Mede a força da regra, indicando a probabilidade condicional de Y ocorrer dado que X ocorreu.

Lift: Mede o quanto mais frequente Y ocorre quando X ocorre, comparado com a frequência esperada se X e Y fossem independentes.

Um valor de lift maior que 1 indica que existe uma correlação positiva entre X e Y, enquanto um valor igual a 1 sugere independência, e um valor menor que 1 indica correlação negativa.

2.3. Algoritmo Apriori

O algoritmo Apriori é uma técnica fundamental na mineração de regras de associação, baseada no princípio de que qualquer subconjunto de um conjunto frequente também deve ser frequente. No contexto de filmes, se muitos usuários que gostaram dos filmes A e B também gostaram do filme C, é provável que um novo usuário que gostou de A e B também goste de C.

2.3.1 Pseudocódigo Algoritmo Apriori

Função APRIORI(D, suporte_minimo)

// D é o conjunto de transações

// suporte_minimo é o limiar de suporte

// Encontrar todos os itens frequentes de tamanho 1

$L_1 = \{i \mid i \in I, \text{suporte}(i) \geq \text{suporte_minimo}\}$

k = 2

Enquanto L_{k-1} não estiver vazio:

// Gerar candidatos de tamanho k

$C_k = \text{gerar_candidatos}(L_{k-1})$

// Calcular suporte dos candidatos

Para cada transação t em D:

Para cada candidato c em C_k :

Se c está contido em t :

$$\text{suporte}(c) = \text{suporte}(c) + 1$$

// Filtrar candidatos pelo suporte mínimo

$$L_k = \{c \mid c \in C_k, \text{suporte}(c) \geq \text{suporte_minimo}\}$$

$$k = k + 1$$

Retornar União de todos os L_k

Função GERAR_CANDIDATOS(L)

// L é o conjunto de itemsets frequentes do nível anterior

Candidatos = $\{\}$

Para cada par de itemsets I_1, I_2 em L :

Se primeiros $(k-2)$ itens de I_1 e I_2 são iguais:

$$c = I_1 \cup \{\text{último item de } I_2\}$$

Se todos os subconjuntos de c de tamanho $(k-1)$ estão em L :

Adicionar c a Candidatos

Retornar Candidatos

Função GERAR_REGRAS(L , confiança_minima)

// L é o conjunto de todos os itemsets frequentes

Regras = $\{\}$

Para cada itemset frequente I em L , onde $|I| \geq 2$:

Para cada subconjunto a de I :

$b = I - a$ // itens em I mas não em a

$\text{confianca} = \text{suporte}(I) / \text{suporte}(a)$

Se $\text{confianca} \geq \text{confianca_minima}$:

Adicionar $a \rightarrow b$ a Regras

Retornar Regras

3. Metodologia

3.1. Conjunto de Dados

Para o desenvolvimento do sistema, foram utilizados dois conjuntos de dados principais:

1. **ratings_small.csv**: Contendo as avaliações dos usuários para diferentes filmes, com informações sobre `userId`, `movieId` e `rating`.
2. **movies_metadata.csv**: Contendo metadados dos filmes, incluindo `id`, `título` e `gêneros`.

3.2. Pré-processamento dos Dados

O processo de pré-processamento dos dados envolveu as seguintes etapas:

1. **Seleção de Colunas Relevantes**: Foram mantidas apenas as colunas essenciais para o sistema de recomendação.
 - Do conjunto `ratings`: `userId`, `movieId` e `rating`
 - Do conjunto `metadata`: `id`, `title` e `genres`
2. **Correção de Tipos de Dados**: Conversão da coluna `'id'` para numérico e renomeação para `'movieId'`.
3. **Unificação dos Dados**: Mesclagem dos conjuntos de dados usando `movieId` como chave.
4. **Filtragem por Avaliações Positivas**: Seleção apenas de avaliações com `rating` maior ou igual a 3.0, consideradas como positivas.

5. **Estruturação do Dataset para Mineração:** Transformação dos dados em formato de "cesta de compras", onde cada usuário representa uma transação, e os filmes avaliados positivamente são os itens.

3.3. Sistema de Recomendação

O sistema de recomendação implementado utiliza duas estratégias distintas:

1. **Recomendação Baseada no Histórico Completo:** Analisa todo o histórico de filmes avaliados positivamente pelo usuário e busca regras cujos antecedentes estejam contidos nesse histórico. Os consequentes dessas regras são candidatos a recomendação.
2. **Recomendação Baseada no Último Filme:** Foca nos filmes mais recentemente avaliados pelo usuário, buscando regras em que esses filmes aparecem tanto como antecedentes quanto como consequentes.
3. **Fallback para Recomendações Populares:** Quando não é possível encontrar recomendações específicas usando as estratégias anteriores, o sistema recomenda filmes populares (com alto suporte) que o usuário ainda não avaliou.

4. Resultados e Discussões

4.1. Configuração dos Experimentos

Os experimentos foram realizados com os seguintes parâmetros:

- Suporte mínimo: 0.1 (10%)
- Confiança mínima: 0.3 (30%)
- Nível máximo de conjuntos: 2

4.2. Conjuntos Frequentes Descobertos

A aplicação do algoritmo Apriori revelou diversos conjuntos de filmes frequentemente avaliados de forma positiva pelos usuários.

Para avaliar a qualidade das recomendações, analisamos os resultados para diferentes perfis de usuários:

1. **Usuários com Histórico Diversificado:** Para usuários que avaliaram positivamente filmes de diferentes gêneros, o sistema tendeu a recomendar filmes populares dentro desses mesmos gêneros, com base nas regras mais fortes.
2. **Usuários com Preferências Específicas:** Para usuários com histórico focado em gêneros específicos (ex.: filmes de ficção científica), o sistema gerou recomendações mais precisas e personalizadas.

3. **Usuários com Poucas Avaliações:** Para estes, o sistema frequentemente recorreu à estratégia de recomendação baseada no último filme assistido ou às recomendações populares.

O uso combinado das duas estratégias de recomendação (histórico completo e último filme) permitiu equilibrar a relevância das recomendações com a diversidade, evitando o problema do "filtro bolha" que pode ocorrer em sistemas que recomendam apenas itens muito similares aos já consumidos pelo usuário.

5. Considerações Finais

5.1. Contribuições

Este trabalho apresentou um sistema de recomendação de filmes baseado em regras de associação, com as seguintes contribuições:

1. Implementação completa do algoritmo Apriori adaptado para o contexto de recomendação de filmes.
2. Desenvolvimento de estratégias híbridas de recomendação que consideram tanto o histórico completo quanto as interações mais recentes do usuário.
3. Criação de uma interface em linha de comando para visualização de recomendações e análise das regras de associação geradas.

5.2. Limitações

Algumas limitações identificadas no trabalho incluem:

1. **Escala:** A implementação atual pode apresentar desafios de desempenho para conjuntos de dados muito grandes, devido à natureza exponencial do algoritmo Apriori.
2. **Cold Start:** O sistema enfrenta dificuldades com novos usuários (sem histórico) e novos itens (sem avaliações suficientes).

5.3. Trabalhos Futuros

Como direções para trabalhos futuros, destacamos:

1. **Hibridização:** Combinação da abordagem baseada em regras de associação com técnicas de filtragem colaborativa ou baseada em conteúdo.
2. **Ajuste Dinâmico de Parâmetros:** Desenvolvimento de métodos para ajustar automaticamente os valores de suporte e confiança mínimos com base no perfil do usuário.
3. **Incorporação de Informações Temporais:** Inclusão de pesos temporais para dar maior relevância às avaliações mais recentes.
4. **Avaliação com Usuários Reais:** Realização de testes com usuários reais para avaliar a relevância percebida das recomendações.

5.4. Conclusão

O sistema de recomendação baseado em regras de associação apresentou resultados promissores para a tarefa de recomendar filmes com base no histórico de avaliações dos usuários. A abordagem proposta demonstrou capacidade de identificar padrões relevantes nas preferências dos usuários e utilizá-los para gerar recomendações personalizadas.

A combinação de diferentes estratégias de recomendação, juntamente com a análise de métricas como suporte, confiança e lift, proporcionou um equilíbrio entre relevância e diversidade nas recomendações geradas. Embora existam limitações, especialmente relacionadas à escalabilidade e ao problema do cold start, o sistema desenvolvido representa uma base sólida para futuras melhorias e extensões.

Referências

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules. In: Proceedings of the 20th International Conference on Very Large Data Bases (VLDB), 1994, p. 487-499.

KAMBER, M.; HAN, J.; PEI, J. Data Mining: Concepts and Techniques. 3rd Edition, Morgan Kaufmann, 2011.

RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. B. Recommender Systems Handbook. Springer, 2011.

SCHAFER, J. B.; KONSTAN, J. A.; RIEDL, J. E-commerce recommendation applications. Data Mining and Knowledge Discovery, v. 5, n. 1-2, p. 115-153, 2001.

TAN, P. N.; STEINBACH, M.; KUMAR, V. Introduction to Data Mining. Pearson Education, 2006.